#### Описание задачи.

Разработать ETL процесс, получающий ежедневную выгрузку данных (предоставляется за 3 дня), загружающий ее в хранилище данных и ежедневно строящий отчет.

# Выгрузка данных.

Ежедневно некие информационные системы выгружают следующие файлы:

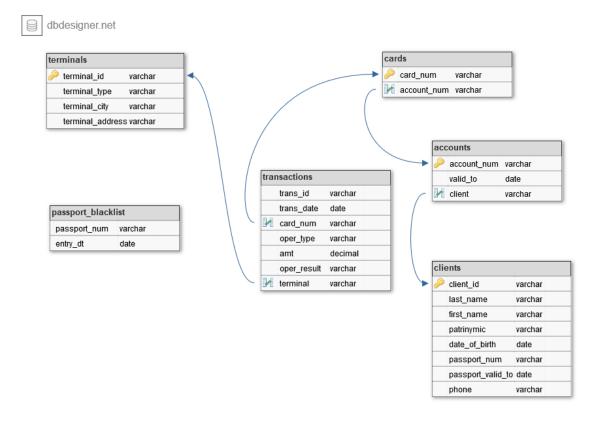
- 1. Список транзакций за текущий день. Формат CSV.
- 2. Список терминалов полным срезом. Формат XLSX.
- 3. Список паспортов, включенных в «черный список» с накоплением с начала месяца. Формат XLSX.

Сведения о картах, счетах и клиентах хранятся в СУБД Oracle в схеме BANK.

Вам предоставляется выгрузка за последние три дня, ее надо обработать.

### Структура хранилища.

Данные должны быть загружены в хранилище со следующей структурой (имена сущностей указаны по существу, без особенностей правил нейминга, указанных далее):



Типы данных в полях можно изменять на однородные если для этого есть необходимость. Имена полей менять нельзя. Ко всем таблицам SCD1 должны быть добавлены технические поля create\_dt, update\_dt; ко всем таблицам SCD2 должны быть добавлены технические поля effective\_from, effective\_to, deleted flg.

# Построение отчета.

По результатам загрузки ежедневно необходимо строить витрину отчетности по мошенническим операциям. Витрина строится накоплением, каждый новый отчет укладывается в эту же таблицу с новым report dt.

В витрине должны содержаться следующие поля:

event_dt	Время наступления события. Если событие наступило по	
	результату нескольких действий – указывается время действия,	
	по которому установлен факт мошенничества.	
passport	Номер паспорта клиента, совершившего мошенническую	
	операцию.	
fio	ФИО клиента, совершившего мошенническую операцию.	
phone	Номер телефона клиента, совершившего мошенническую	
	операцию.	
event_type	Описание типа мошенничества.	
report_dt	Время построения отчета.	

### Признаки мошеннических операций.

- 1. Совершение операции при просроченном или заблокированном паспорте.
- 2. Совершение операции при недействующем договоре.
- 3. Совершение операций в разных городах в течение одного часа.
- 4. Попытка подбора суммы. В течение 20 минут проходит более 3х операций со следующим шаблоном каждая последующая меньше предыдущей, при этом отклонены все кроме последней. Последняя операция (успешная) в такой цепочке считается мошеннической.

# Правила именования таблиц.

Необходимо придерживаться следующих правил именования (для автоматизации проверки):

DEMIPT. <code>_STG_<table_name></table_name></code>	Таблицы для размещения
DENTI 1: \GODE\_O1G_\IN\DEC_\IN\III	стейджинговых таблиц
	(первоначальная загрузка),
	промежуточное выделение
	инкремента если требуется.
	Временные таблицы, если
	такие потребуются в
	расчете, можно также
	складывать с таким
	именованием.
	Имя таблиц можете
	выбирать произвольное, но
	смысловое.
<pre>DEMIPT.<code>_DWH_FACT_<table_name></table_name></code></pre>	Таблицы фактов,
	загруженных в хранилище. В
	качестве фактов выступают
	сами транзакции и «черный
	список» паспортов.
	Имя таблиц – как в ER
	диаграмме.
<pre>DEMIPT.<code>_DWH_DIM_<table_name></table_name></code></pre>	Таблицы измерений,
	хранящиеся в формате SCD1.
	Имя таблиц – как в ER
	диаграмме.
DEMIPT. < CODE > _ DWH _ DIM _ < TABLE _ NAME > _ HIST	Таблицы измерений,
	хранящиеся в SCD2 формате
	(только для тех, кто
	выполняет усложненное
	задание).
	Имя таблиц – как в ER
	диаграмме.
DEMIPT. <code>_REP_FRAUD</code>	Таблица с отчетом.
DEMIPT. <code>_META_<table_name></table_name></code>	Таблицы для хранения
	метаданных.
	Имя таблиц можете
	выбирать произвольное, но
	смысловое.
	CIVIDIC/IODOC.

<CODE> - 4 буквы вашего персонального кода.

Если результирующее имя не удовлетворяет ограничениям Oracle – необходимо из имени таблицы удалить гласные буквы:

PASSPORT\_BLACKLIST = PSSPRT\_BLCKLST

# Обработка файлов

Выгружаемые файлы именуются согласно следующему шаблону:

```
transactions_DDMMYYYY.txt
passport_blacklist_DDMMYYYY.xlsx
terminals_DDMMYYYY.xlsx
```

Предполагается что в один день приходит по одному такому файлу. После загрузки соответствующего файла он должен быть переименован в файл с расширением .backup чтобы при следующем запуске файл не искался и перемещен в каталог archive:

```
transactions_DDMMYYYY.txt.backup
passport_blacklist_DDMMYYYY.xlsx.backup
terminals_DDMMYYYY.xlsx.backup
```

Желающие могут придумать, обосновать и реализовать более технологичные и учитывающие сбои способы обработки (за это будет повышен балл).

# Проверка результата.

Проверка задания состоит из нескольких частей, обязательных к одновременному выполнению.

1. Загрузка в ЦДПО.

В ЦДПО выкладывается zip-apхив, содержащий следующие файлы и каталоги:

main.py	Файл,	Основной процесс
	обязательный	обработки.
файлы с данными	Файл,	Те файлы, которые вы
	обязательный	получили в качестве
		задания.
main.cron	Файл,	Файл для постановки
	обязательный	вашего процесса на
		расписание, в формате
		crontab
archive	Каталог,	Пустой, сюда должны
	обязательный	перемещаться
		отработанные файлы
sql_scripts	Каталог,	Если вы включаете в
	необязательный	main.py какие-то SQL
		скрипты, вынесенные в
		отдельные файлы –
		помещайте их сюда.

py_scripts	Каталог,	Если вы включаете в
	необязательный	main.py какие-то python
		скрипты, вынесенные в
		отдельные файлы –
		помещайте их сюда.

Имя архива – 4 буквы вашего кода с расширением .zip. Например, CHRN. zip.

# 2. Данные в таблицах на сервере.

Данные в ваших таблицах должны быть загружены за все три дня. Данные в таблицах будут проверены автоматически исходя из правил наименования. Будьте внимательны, если имя таблицы не соответствует выставленным требованиям – проверка не происходит, считается что вы не отловили ни один из случаев.

# 3. Код в вашем каталоге на ETL сервере.

Ha cepвepe de-etl.chronosavant.ru должен быть создан каталог /home/demipt/<CODE>, где <CODE> - 4 буквы вашего кода, например /home/demipt/CHRN. В каталоге должны быть выложены точно те же файлы и каталоги, которые вы прислали на проверку в ЦДПО. На файл main.py должны быть выданы права на исполнение.

### Критерии оценки.

К оцениванию проекта невозможно применить некую объективную шкалу оценки (например, 50 строк кода это лучше чем 20 строк кода, или пять таблиц в отчете лучше чем три). Поэтому проект будет оцениваться экспертной оценкой по пяти показателям. В качестве эксперта выступает преподаватель. Оценка выставляется аргументировано и может обсуждаться, но не изменяться. После объявления оценки, если не прошел контрольный срок, можно доработать индивидуальное задание и сдать его на повторную проверку.

У преподавателя есть право добавить дополнительные баллы за сложные решения в проекте (не сложное решение простой задачи, а именно решение сложной задачи).

#### Критерии выставления оценки:

1. Структурированность кода – восприятие кода (отступы, табуляции), комментирование, разделение на отдельные файлы логических блоков. **До 10%.** 

- 2. Качество обработки инкремента. Инкремент должен выделяться правильно, максимально эффективно и без лишних операций, контроль проводится в том числе автоматически по нескольким операциям. **До 15%.**
- 3. Общая сложность процесса обработки данных. При выполнении задания необходимо придерживаться стандартов, изученных в курсе. Необоснованное обработки процесса будет снижать балл. Приветствуется ухудшение использование изученных алгоритмов загрузки данных хранилище, использование метаданных. До 40%, причем если вы используете только SCD1 - то до 15%.
- 4. Качество получаемого результата. Необходимо найти все предусмотренные мошеннические операции. У нас заготовлено 7 проверок (4 позитивных примера и 3 контрпримера), по 5% за каждую найденную операцию. Мошеннических операций может быть больше, но контролируются 7 из них. Итого до 35%.
- 5. Дополнительные баллы за сложность. Проверяющий оставляет за собой право добавлять **до 25%** дополнительных баллов за дополнительное полезное улучшение (и усложнение) проекта.

Минимальные требования, для того чтобы мы считали проект успешно выполненным – успешная загрузка одной фактовой таблицы и одной таблицы измерений, отлов хотя бы одного случая мошенничества в отчете и минимальный балл за все задание 35%.